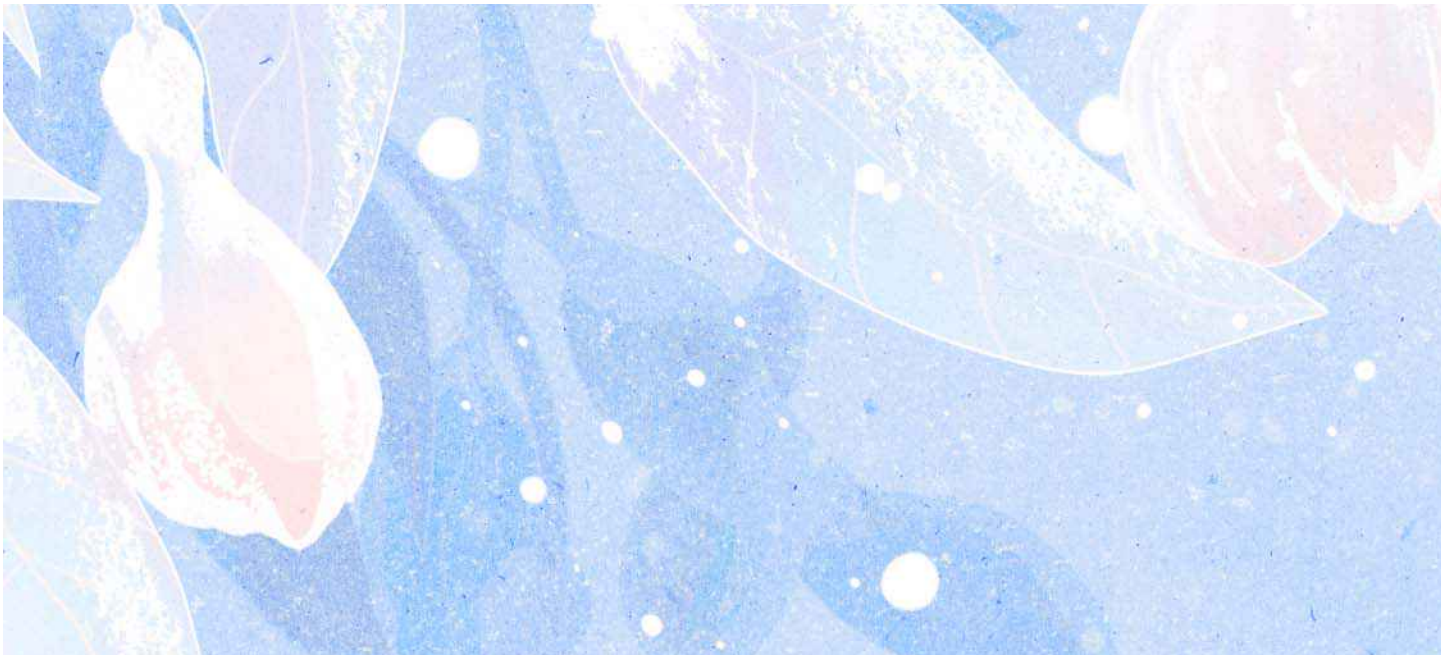

青训营结业项目答辩汇报--Hello, Flink组（项目二）

一、项目介绍

> 我们组选择的是项目二，目前已经完成了大约80%，实现了WordCount小程序初级功能和Watermarks处理乱序延迟数据的中级功能，Retract和自动故障恢复由于时间比较紧张所以还没有完成，然后Exactly Once高级功能只写好了相应的配置，还没有设计相应的案例进行测试。通过测试，目前已写好的功能基本都能实现，满足题目所提的要求。
>
> 项目服务地址-必须
>
> Github 地址，权限设置为 public- 必须

二、项目分工

> 好的团队协作可以酌情加分哟～请组长和组员做好项目分工与监督。

团队成员	主要贡献
朱骏凯	作为组长，参与项目初级功能和中级功能的讨论，设计，编码开发以及测试工作（贡献度30%）
伍莞秋	参与项目初级功能的讨论，设计，编码开发以及测试工作（贡献度25%）
房哲	参与项目中级功能的讨论，设计，编码开发以及测试工作（贡献度25%）
谢立国	参与项目的文档撰写和整理（贡献度10%）
郭世哲	参与项目的测试（贡献度10%）

三、项目实现

3.1 技术选型与相关开发文档

> 可以补充场景分析环节，明确要解决的问题和前提假设，比如按当前选型和架构总体预计需要xxx存储空间，xxx台服务器.....。

本次的项目均在Win10本地电脑进行开发和测试，后期会考虑打包上传到Linux服务器进行测试，毕竟Kafka更适用于Linux上进行配置。

3.2 架构设计

> 可以补充场景分析环节，明确要解决的问题和前提假设，比如预计0.5%的用户属于大V，粉丝很多，也会经常上传视频，当前架构的解决方案是xxx。

Flink的开发我们都按照标准的“Source -> Transformation -> Sink”的有向无环图DAG格式进行设计和开发。其中Source用了多种形式进行实现，比如说预定义的

fromElements，自己撰写了一个可以源源不断产生数据的类，Socket，Kafka等；Transformation使用了flatMap、Map、keyBy、sum、reduce等多种算子，同时设置了滚动窗口，将全量和增量窗口结合进行使用，并设置了Watermarks处理延迟乱序数据；Sink同时开发了输出到控制台以及输出到.txt两种输出方式。

总体来看，整个开发的架构还是很有层次的，而且代码处都有相应的注释。

3.3 项目代码介绍

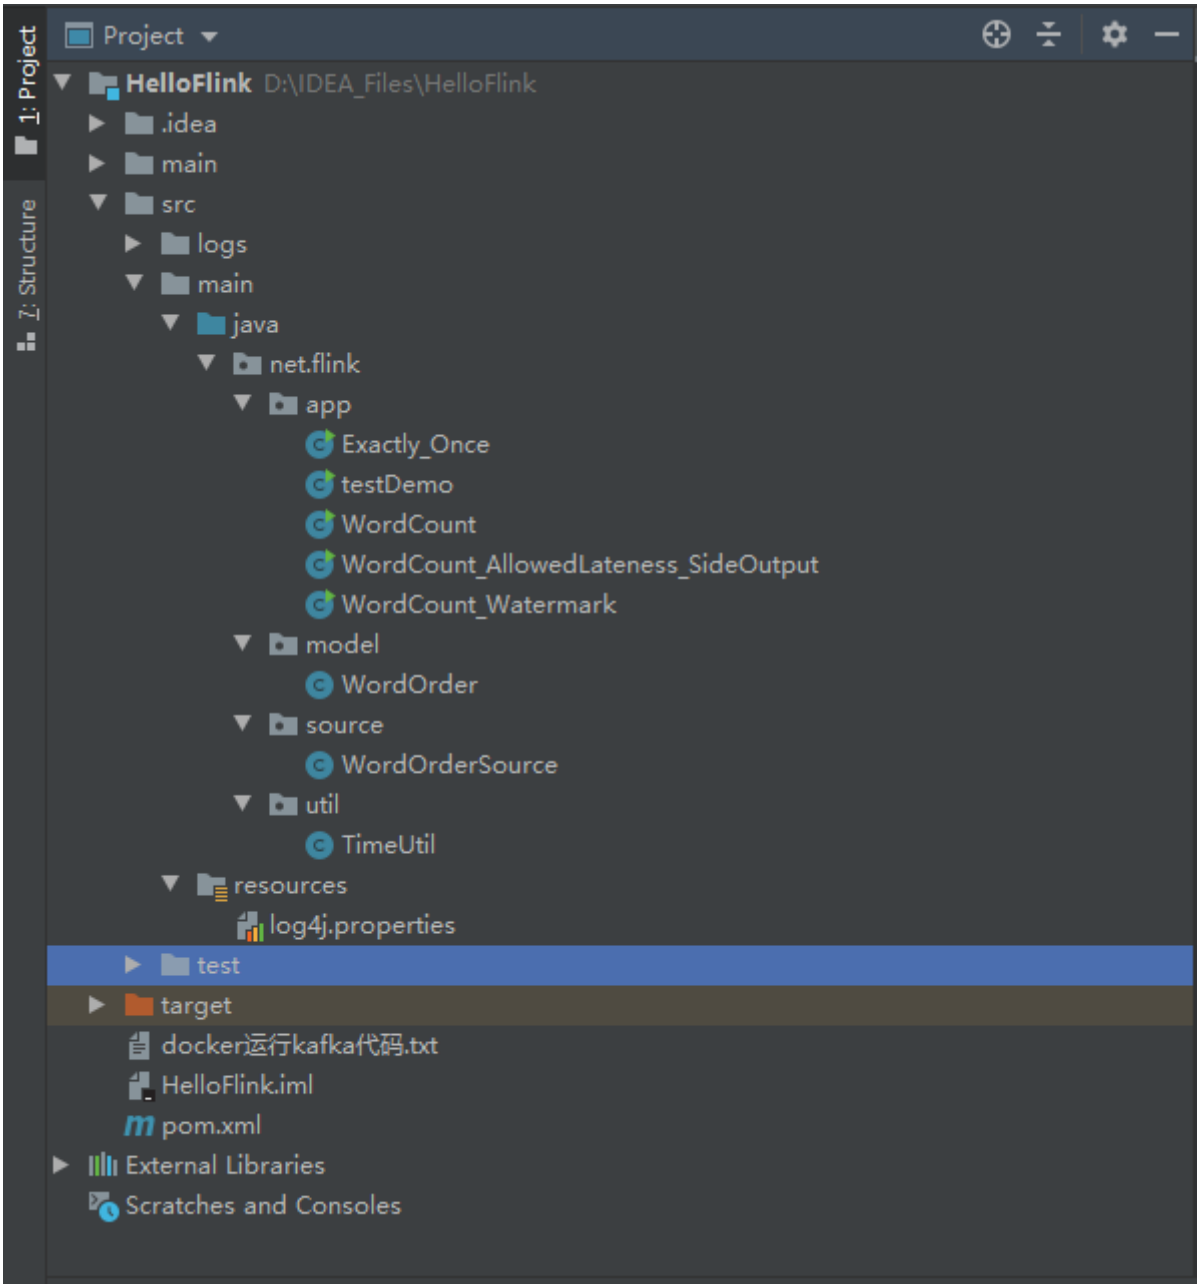

上图为整个项目的代码结构：

pom.xml：添加相应的依赖

log4j.properties：日志管理

TimeUtil：时间格式转换类，包含Date类型转String类型、Long类型转String类型以及String类型转Date类型共三种应用场景

WordOrder：构造一个类存放输入的数据时间、单词以及个数

WordOrderSource：构造一个类产生源源不断随机产生输入数据

WordCount：统计5mins内每个单词的数量，我这边做了一个改进：就是不局限于一条记录一个单词只产生一次，而是让用户自己定义单词的数量。使用增量和全量窗口相结合的方式，在节省资源提高效率的同时还返回了窗口的时间信息

WordCount_Watermark：设置Watermarks机制处理延迟乱序数据，其中设置窗口大小为10s，延迟时间为3s

WordCount_AllowedLateness_SideOutput：在Watermarks的基础上设置allowedLateness二次兜底延迟数据处理和SideOutput兜底延迟数据处理，二次兜底时间为1min

Exactly_Once：写好了Exactly Once Checkpoint的相关配置，但相应的测试案例还没设计好

备注：

1.Kafka作为Source的代码我也写好了，但是由于其更适合用于Linux上进行测试，因此我在WordCount小程序中使用自己定义的类源源不断地产生数据流代替进行测试，然后Watermarks那里采用Socket和nc方法代替进行测试，效果都是一样的

2."testDemo"是一个实现字符串切割的flink测试demo,与本项目无关

五、测试结果

> 建议从功能测试和性能测试两部分分析，其中功能测试补充测试用例，性能测试补充性能分析报告、可优化点等内容。

(1). 功能测试

①.WordCount

测试用例：

WordOrderSource源源不断随机产生的WordOrder数据记录（每隔1s产生1条数据）

输出结果：

每隔5mins统计一次单词数量

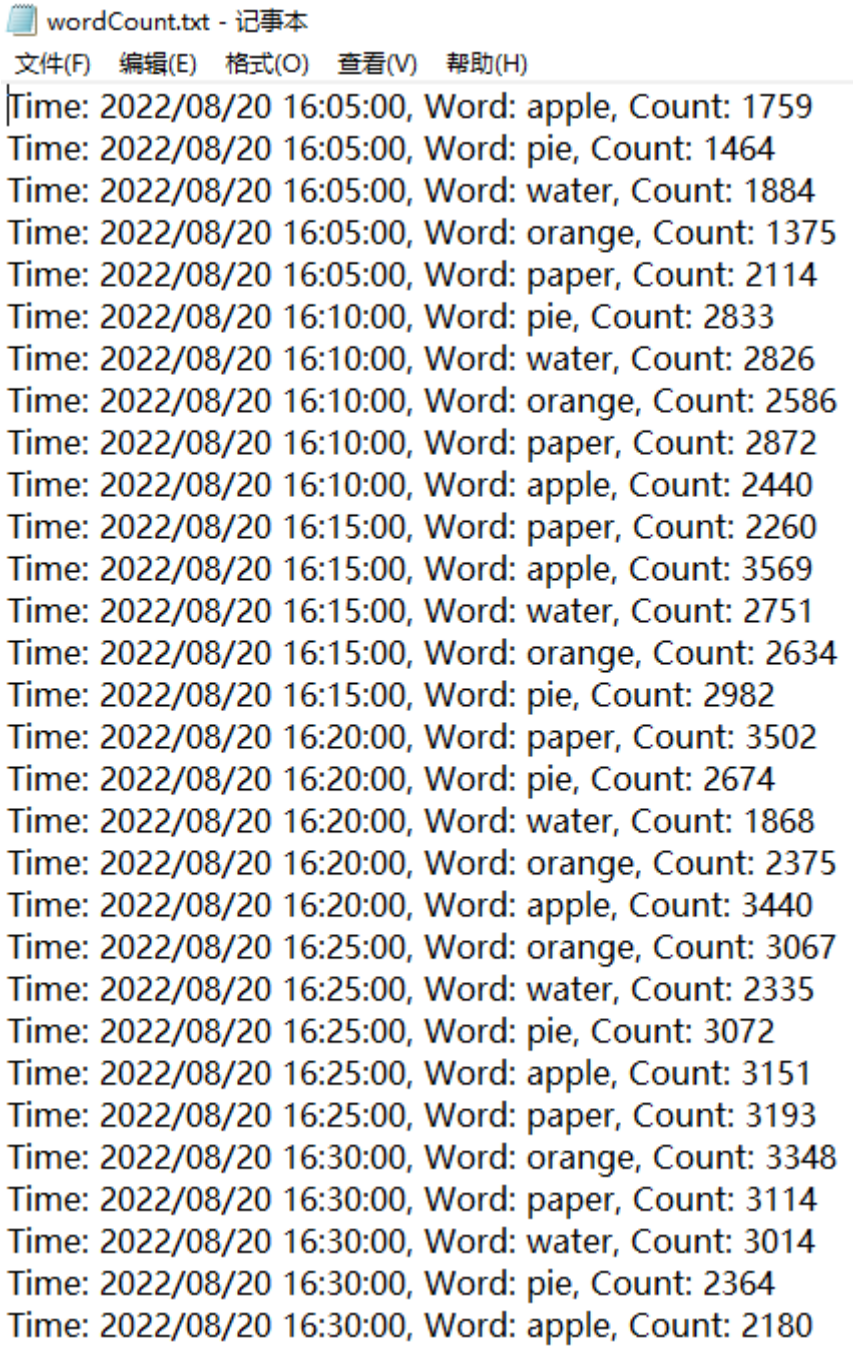

②.Watermarks

测试用例（在nc中依次输入）：

2023/01/01 11:24:07,java,15 //窗口1计算
2023/01/01 11:24:11,java,15 //窗口2计算
2023/01/01 11:24:08,java,15 //窗口1计算
2023/01/01 11:24:13,java,15 //窗口2计算,同时watermarks触发窗口1计算
2023/01/01 11:24:17,java,15 //窗口2计算
2023/01/01 11:24:09,java,15 //窗口计算结束,该记录将被丢弃不输出
2023/01/01 11:24:20,java,15 //左闭右开,窗口3计算
2023/01/01 11:24:22,java,15 //窗口3计算
2023/01/01 11:24:23,java,15 //窗口3计算,同时watermarks触发窗口2计算

2023/01/01 11:24:25,java,15 //窗口3计算
2023/01/01 11:24:40,java,15 //窗口4计算,同时watermarks触发窗口3计算

输出结果：

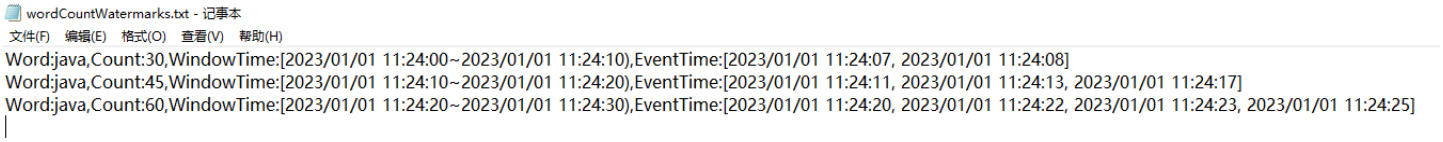

③.AllowedLateness & SideOutput

测试用例（在nc中依次输入）：

2023/01/01 11:24:07,java,15 //窗口1计算
2023/01/01 11:24:11,java,15 //窗口2计算
2023/01/01 11:24:08,java,15 //窗口1计算
2023/01/01 11:24:13,java,15 //窗口2计算,同时watermarks触发窗口1计算
2023/01/01 11:24:23,java,15 //窗口3计算,同时watermarks触发窗口2计算
2023/01/01 11:24:09,java,15 //allowedLateness窗口1重新计算
2023/01/01 11:24:12,java,15 //allowedLateness窗口2重新计算
2023/01/01 11:24:02,java,15 //allowedLateness窗口1重新计算
2023/01/01 11:25:24,java,15 //延迟超过allowedLateness设定的1min
2023/01/01 11:24:05,java,15 //SideOutput输出
2023/01/01 11:24:08,java,15 //SideOutput输出
2023/01/01 11:24:18,java,15 //SideOutput输出

输出结果：

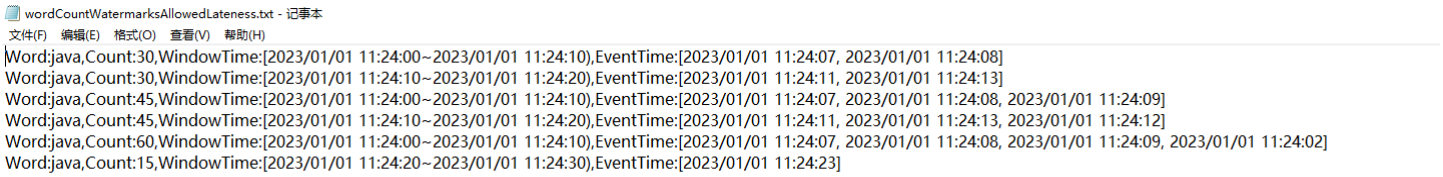

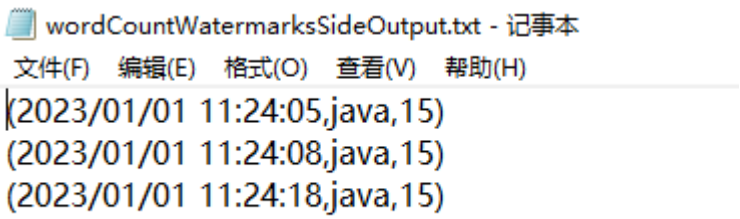

(2). 性能测试

经测试，该程序响应速度满足预期设计，运行效果良好

六、演示 Demo （必须）

视频演示：

链接：https://pan.baidu.com/s/1GxvlpcyF-eCIXJweyKQ6sw

提取码：q9wr

七、项目总结与反思

1. 目前仍存在的问题

(1).Retract计算和故障恢复由于时间问题还没有完成

(2).代码和程序性能的优化

2. 已识别出的优化项

代码和程序性能以及功能

3. 架构演进的可能性

DAG流程设计进一步优化，减少资源消耗，提高效率

4. 项目过程中的反思与总结

通过这个项目，小组成员能够在总体上了解Flink流式计算的实现原理，通过动手实践掌握基本的Flink流式计算框架的编写，实现特定的功能，了解窗口和Watermarks的机制并动手实际和测试，了解Exactly Once的原理和代码配置等等。

> 总的来说，通过这次课程和项目实践，大家都收获颇丰，希望以后能有更多的机会参加这样类似的课程和项目实践。
>
> 参考资料：
>
> 1. 青训营课程
> 2. 项目提供的参考文档以及网上的一些参考资料
> 3. 小滴课堂“新一代流式计算框架Flink 1.13”视频教程